

Сценарий защиты ВКР — Лапова Мария Сергеевна

Тема: Разработка кроссплатформенного приложения для прогноза показателей InBody с адаптацией тренировок

Время: ~11 минут (18 слайдов)

Можно читать прямо по тексту. Жирным выделены ключевые цифры — на них держи интонацию. После каждого слайда — пауза 1–2 секунды и переход.

ПОЛНЫЙ ТЕКСТ РЕЧИ

Слайд 1 — Титульный (~15 сек)

Здравствуйте, уважаемые члены комиссии.

Лапова Мария Сергеевна, группа МММ-401-О-03. Тема — «Разработка кроссплатформенного приложения для прогноза показателей InBody с адаптацией тренировок». Научный руководитель — доцент Агафонов Алексей Леонидович.

Слайд 2 — Актуальность (~60 сек)

Сейчас много людей тренируются сами, без тренера. Во многих фитнес-клубах стоит аппарат InBody — он замеряет вес, процент жира, мышечную массу. Но дальше человек остаётся с этими цифрами один на один. Он не понимает: я двигаюсь к своей цели или нет? Если продолжу так же — что будет через месяц?

Фитнес-приложения — Nevy, Strong, Fitbod — помогают записывать тренировки, но ни одно из них не отвечает на этот вопрос. Нет прогноза и нет адаптации плана по результатам замеров.

Мы сделали приложение Portal, которое берёт данные InBody, строит прогноз на одну–четыре недели вперёд и автоматически предлагает обновить план тренировок, если что-то меняется.

Слайд 3 — Цель и задачи (~40 сек)

Цель — разработать приложение Portal для прогноза состава тела и адаптации тренировочного плана.

Задачи: проанализировать предметную область — что уже есть на рынке и чего не хватает; разработать ML-модель прогноза; создать серверную часть — REST API; реализовать клиентское приложение в формате PWA; и протестировать систему.

Слайд 4 — Разделение работ (~25 сек)

Работу мы делали в паре с Егором Ощепковым.

Моя часть — прогноз состава тела: ML-модель, доверительные интервалы, синтез данных и импорт PDF-отчётов InBody, — а также сервис адаптации плана. Егор отвечал за генератор тренировок: каталог упражнений, ранжирование и учёт тренировок. Общую концепцию, архитектуру, REST API, клиент и базу данных делали совместно.

Слайд 5 — Сравнение с аналогами (~50 сек)

На этом слайде — таблица сравнения с существующими приложениями.

Nevu и Strong — дневники тренировок, без прогноза и без InBody. Fitbod генерирует планы, но тоже без прогноза состава тела. MacroFactor умеет прогнозировать только вес — без жира и мышц и без InBody. DDX Fitness — российское приложение, работает с InBody-замерами, но только записывает их, прогноза нет.

Portal — единственное решение, которое сочетает прогноз трёх показателей, работу с InBody и автоматическую адаптацию плана.

Слайд 6 — Архитектура системы (~40 сек)

Здесь — схема архитектуры приложения.

Пользователь работает через Flutter-приложение в браузере. Оно обращается к серверу на FastAPI. Сервер работает с базой данных PostgreSQL, хранилищем файлов MinIO — туда загружаются PDF-отчёты InBody — и с модулем машинного обучения на LightGBM. Отдельно работает сервис адаптации, который следит за изменениями в профиле.

Слайд 7 — Схема базы данных (~25 сек)

Это схема базы данных моей подсистемы.

В центре — пользователь. К нему привязаны профиль и история InBody-замеров; замеры могут приходиться из загруженного PDF. На основе замеров строятся прогнозы, а их качество оценивается в отдельной таблице — сравнением прогноза с фактическим замером. Отдельно — журнал событий адаптации плана. Всего в системе около двадцати связанных таблиц.

Слайд 8 — Основные функции (~40 сек)

Что умеет приложение.

Прогноз состава тела — вес, процент жира, мышечная масса на одну, две и четыре недели вперёд. Генерация плана тренировок на четыре недели под параметры пользователя. Импорт PDF-отчётов InBody — можно загрузить PDF из клуба, и приложение само вытащит нужные цифры. Рекомендации по нормам ВОЗ — например, если процент жира выше нормы, приложение об этом скажет. И автоадаптация плана — если вес сдвинулся или поменялась цель, приложение само предложит обновить программу.

Слайд 9 — ML-модель прогноза (~60 сек)

Прогнозируем три показателя — вес, процент жира и мышечную массу — на горизонтах одна, две и четыре недели.

Мы сравнили три модели. Ridge-регрессия — линейная, служит базовой для сравнения. LightGBM — градиентный бустинг, он показал лучший результат и стал основной моделью. И нейросеть на PyTorch — альтернативная архитектура, которая подтвердила результат LightGBM.

Для доверительных интервалов используется квантильная регрессия — модель обучается на трёх квантилях и выдаёт не одну цифру, а коридор: нижнюю границу, прогноз и верхнюю границу.

Готовых временных рядов InBody в открытом доступе нет, поэтому мы взяли **973** профиля посетителей фитнес-клубов с Kaggle и для каждого синтезировали восьминедельную траекторию по формулам дефицита и профицита калорий.

Слайд 10 — Как работает прогноз (~30 сек)

Покажу, как устроен прогноз внутри.

На вход берём последний InBody-замер и профиль. Из них собираем **12 признаков** — вес, рост, процент жира, мышечную массу, индекс массы тела

и другие. Признаки идут в LightGBM, который выдаёт три квантиля: нижнюю границу, прогноз и верхнюю. Прогноз делается на неделю вперёд, потом результат снова подаётся на вход — так рекурсивно получаем горизонты одна, две и четыре недели. На выходе — прогноз с доверительным интервалом и текстовая интерпретация.

Слайд 11 — Последовательность обработки запроса (~30 сек)

На этой диаграмме последовательности видно, как запрос проходит через слои приложения.

Пользователь открывает экран «Прогноз», клиент шлёт запрос на сервер. Сервер собирает признаки по замерам и вызывает ML-модель. Модель возвращает изменения по трём показателям с интервалом; результат возвращается на экран — и пользователь видит график с лентой доверительного интервала.

Слайд 12 — Доверительные интервалы (~40 сек)

Подробнее про интервалы. Мы обучаем модель на три квантиля: ноль-целых-одна-десятая — нижняя граница, ноль-целых-пять — сам прогноз, ноль-целых-девять — верхняя граница. Это даёт **80-процентный** доверительный интервал.

На тестовой выборке проверили: в **79%** случаев реальное значение попало в предсказанный коридор — при заявленных 80%. Значит, интервал честный, не завышен и не занижен.

Всего работает девять бустеров: три показателя умножить на три квантиля.

Слайд 13 — Алгоритм адаптации плана (~40 сек)

Вторая часть работы — сервис, который следит за профилем пользователя и предлагает обновить план.

Четыре триггера. Вес изменился больше чем на два килограмма.

Пользователь сменил цель — например, с похудения на набор массы.

Изменилась частота тренировок. Или закончился четырёхнедельный цикл.

Когда срабатывает любое условие — пользователь видит предложение обновить план. Если не реагирует семь дней — план обновляется автоматически.

Слайд 14 — Сравнение ошибок по моделям (~45 сек)

В этой таблице — метрики прогноза изменения веса для всех четырёх моделей.

Базовая модель «ничего не изменится» — худшая: средняя ошибка **0,325** килограмма и отрицательный R^2 . Ridge заметно лучше. А LightGBM и нейросеть дают лучший результат — средняя ошибка **0,156** килограмма, R^2 равен **0,73**, и это на **52%** точнее базовой модели.

R^2 равный 0,73 означает, что модель объясняет 73 процента изменений показателя.

Слайд 15 — Результаты: сравнение моделей (~35 сек)

А на этом графике — та же картина, но уже по всем трём показателям сразу: изменение веса, процента жира и мышечной массы.

Видно, что по каждому показателю базовая модель проигрывает, а LightGBM и нейросеть идут вровень и дают самую низкую ошибку. Основной моделью выбран LightGBM — он быстрее на отклик и проще в интерпретации.

Слайд 16 — Интерфейс приложения (~25 сек)

Несколько экранов готового приложения.

Слева — главный экран: сводка по профилю и быстрый доступ к функциям. В центре — загрузка и анализ InBody: можно загрузить PDF-отчёт из клуба, и приложение само распознаёт показатели. Справа — статистика прогресса: графики динамики веса, жира и мышечной массы с прогнозом и доверительным интервалом.

Приложение уже развёрнуто и работает — по QR-коду на следующем слайде его можно открыть и попробовать прямо сейчас.

Слайд 17 — Заключение (~40 сек)

Что сделано.

Создано кроссплатформенное приложение Portal на FastAPI и Flutter. Реализован прогноз состава тела с R^2 равным **0,73** и калиброванным доверительным интервалом. Реализована автоматическая адаптация плана тренировок при изменении профиля. Работоспособность системы подтверждена на тестовой выборке и покрыта автотестами.

Слайд 18 — Спасибо (~10 сек)

Спасибо за внимание. По QR-коду на слайде приложение можно открыть и попробовать прямо сейчас.

(Дальше — вопросы комиссии.)

ТЕЗИСЫ-ШПАРГАЛКА

#	Слайд	Опорные точки	Время
1	Титул	Представиться, тема, руководитель	15с
2	Актуальность	InBody без интерпретации; аналоги не прогнозируют; Portal	60с
3	Цель и задачи	Portal + прогноз + адаптация; 5 задач	40с
4	Разделение работ	Я: прогноз + адаптация; Егор: тренировки; общее: архитектура	25с
5	Сравнение	Hevy/Fitbod/MacroFactor/DDX — Portal единственный с тремя «плюсами»	50с
6	Архитектура	Flutter → FastAPI → PG + MinIO + LightGBM + адаптация	40с
7	Схема БД	~20 таблиц; user → замеры → прогноз → оценка; адаптация	25с
8	Функции	Прогноз, план, PDF InBody, рекомендации, адаптация	40с
9	ML-модель	Ridge / LightGBM / нейросеть; квантильная регрессия; 973 профиля + синтез	60с
10	Как работает прогноз	замер → 12 признаков → LightGBM q10/50/90 → рекурсия 1/2/4 нед	30с
11	Последовательность	экран → сервер → ML → график с интервалом	30с
12	Интервалы	3 квантиля → 80%-интервал; 79% попадание; 9 бустеров	40с
13	Адаптация	4 триггера; 7 дней → авто	40с

14	Таблица ошибок	baseline 0,325 → LightGBM 0,156; $R^2=0,73$; на 52% лучше	45с
15	График результатов	по 3 показателям; LightGBM — основная (скорость + интерпретация)	35с
16	Интерфейс приложения	3 экрана: главный · InBody · статистика; уже развёрнуто	25с
17	Заключение	Portal, $R^2=0,73$, адаптация, тесты	40с
18	Спасибо	QR — попробовать приложение	10с

Итого: ~10–11 мин (с запасом на паузы)

ВОПРОСЫ КОМИССИИ

Почему прогнозируете изменение (дельту), а не абсолютное значение?

Если предсказывать абсолют — модель просто копирует входной вес на выход. Формально ошибка маленькая, а пользы ноль. С дельтами модель ловит реальное изменение, а не переписывает текущее значение.

Датасет синтетический — применимо ли это на реальных данных?

Синтез строится по формулам дефицита и профицита калорий, динамика правдоподобная. Но реальные данные шумнее. Поэтому все строки помечены флагом синтетичности — чтобы потом подмешать реальные данные от пользователей и дообучить модель. Плюс есть запасной режим на случай, если модель начнёт ошибаться на реальных данных.

Почему основной выбрали LightGBM, а не нейросеть?

Точность одинаковая — ошибка различается в третьем знаке. Но LightGBM быстрее на отклик и проще в интерпретации. Для табличных данных с 12 признаками оба метода сходятся к одной точности — это известный результат, поэтому смысла усложнять нейросетью нет.

Что если ML-модели нет на сервере или данных мало?

API работает и без неё. Если модель есть и замеров достаточно — используем ML. Если нет — переключаемся на простую базовую модель. Пользователь всё равно получит прогноз.

Как именно разделена работа с Ощепковым?

Егор — генератор планов тренировок: ранжирование упражнений и сборка плана. Я — прогноз InBody, рекомендации и адаптация. Общее — архитектура, авторизация, интерфейс.

Откуда взяты нормы для рекомендаций?

Процент жира — по рекомендациям ВОЗ с поправкой на пол. Процент воды и висцеральный жир — референтные диапазоны прибора InBody. BMR — формула Mifflin–St Jeor. Белок и минералы — нормы ВОЗ.

Что такое квантильная регрессия простыми словами?

Обычная модель выдаёт одну цифру — прогноз. Квантильная выдаёт три: оптимистичный, средний и пессимистичный. Из них получается коридор — «скорее всего значение будет в этих границах». Мы проверили: в 79 случаях из 100 так и есть.

Какие ограничения и что можно улучшить?

Датасет синтетический — нужно копить реальные данные. Метрики считались на неделю вперёд — для двух и четырёх недель ошибка может накапливаться. Если появятся длинные истории замеров — стоит попробовать рекуррентные сети.